

Régression linéaire

Lorsqu'on dispose d'un ensemble de données, il est parfois intéressant de les approximer à l'aide de polynômes. La figure 1 montre un exemple de jeu de données $(x_i; y_i)$. Par exemple la variable x peut représenter l'âge d'un individu et y sa taille. L'objectif ici est d'approximer cet ensemble de données par un polynôme.




Figure 1. Exemple de jeu de données. La moyenne des données est indiquée par la courbe rouge.

Une première approximation consiste à approximer les données à l'aide d'un polynôme de degré 0 : il s'agit de la moyenne des y_i : sur la figure 1 il s'agit de la droite horizontale rouge.

Afin d'apporter plus de nuances dans l'approximation, on peut souhaiter représenter les données par un polynôme de degré 1 : l'objectif est de trouver l'équation de la droite qui représente le mieux les données, comme dans la figure 3.

Considérons une mesure issue du jeu de données, comme montré sur la figure 2. Le point de la mesure a pour coordonnées $(x_i; y_i)$. Si l'on écrit l'équation de la droite d'approximation comme $y = ax + b$, alors l'écart entre la valeur mesurée y_i et celle prédite par la droite vaut :

$$\delta_i = y_i - (ax_i + b).$$

L'objectif est de minimiser cet écart pour toutes les données du jeu. On va donc chercher à minimiser la somme des carrés des écarts :

$$E(a, b) = \sum_{i=1}^N \delta_i^2 = \sum_{i=1}^N (y_i - (ax_i + b))^2$$

L'erreur globale E dépend des 2 variables a et b . Pour trouver les valeurs adéquates et chercher un minimum, il suffit de déterminer a et b pour lesquelles les dérivées s'annulent :

$$\frac{\partial E}{\partial a} = 0 \text{ et } \frac{\partial E}{\partial b} = 0$$

Finalement on obtient un système de 2 équations et 2 inconnues (a et b) :

$$\begin{aligned} \sum_{i=1}^N x_i y_i &= a \sum_{i=1}^N x_i^2 + b \sum_{i=1}^N x_i, \\ \sum_{i=1}^N y_i &= a \sum_{i=1}^N x_i + bN. \end{aligned}$$




Figure 2. Zoom sur une mesure issue du jeu de données.

La résolution du système aboutit à :

$$a = \frac{N \sum_{i=1}^N x_i y_i - \sum_{i=1}^N x_i \sum_{i=1}^N y_i}{N \sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2},$$

$$b = \frac{1}{N} \left(\sum_{i=1}^N y_i - a \sum_{i=1}^N x_i \right).$$




Figure 3. Exemple de jeu de données avec approximation par un polynôme de degré 1.

Dans cette partie on a montré comment passer d'un ensemble de données à un modèle simplifié (ici une droite). La détermination des coefficients de la droite peut être vue comme un mécanisme d'apprentissage du modèle à partir des données. Une fois que le modèle a appris à partir des données, il est capable d'utiliser cet apprentissage pour prédire des valeurs. C'est la phase d'inférence : si l'on dispose d'une valeur x , on peut estimer y à partir du modèle (ici l'équation de la droite).